Wprowadzenie do ASR — materiał dla uczestników

Warsztaty BrainHack 2026 — Rozpoznawanie i generowanie mowy
Moduł 1 (15 min) · Prowadzący: Franciszek Kubala, Mateusz Poszelężny - KN AIMed AGH

> Ten materiał towarzyszy wprowadzeniu. Znajdziesz tu definicje, przykłady, słownik pojęć i linki do źródeł. Nie wymaga wiedzy programistycznej.

1. Czym jest ASR?

ASR (Automatic Speech Recognition) = **automatyczne rozpoznawanie mowy**.
To dziedzina, w której komputer „słucha" dźwięku i zamienia go na tekst.

Analogia: wyobraź sobie niewidzialnego stenotypistę, który nigdy się nie męczy i potrafi przepisać godzinę mowy w kilka sekund.

Ważne rozróżnienie: ASR daje **tekst**. To dopiero pierwszy krok — potem tekst można analizować, streszczać, przeszukiwać. Samo „rozumienie" mowy to osobne zagadnienie.

2. Trzy filary

2.1 Speech-to-text (transkrypcja) — mowa → tekst

- **Definicja:** zamiana nagrania mowy na tekst pisany.
- **Synonimy:** STT, transkrypcja, rozpoznawanie mowy.
- **Przykłady:** napisy do filmów i seriali, dyktowanie na telefonie, notatki ze spotkań, polecenia głosowe („zadzwoń do..."), wyszukiwanie głosowe.
- **Analogia:** jakby ktoś przepisał nagranie słowo po słowie.

2.2 Text-to-speech (TTS) — tekst → mowa

- **Definicja:** zamiana tekstu na mowę — syntetyczny głos.
- **Zastosowania:** czytniki ekranu (dostępność dla osób z niepełnosprawnościami wzroku), audiobooki, asystenci głosowi, powiadomienia, nawigacja.
- **Voice cloning (klonowanie głosu):** z około minuty nagrania można stworzyć głos przypominający konkretną osobę.
- **Etyka:** klonowanie głosu wymaga **zgody** osoby, której głos klonujemy. Bez zgody to nadużycie (deepfake audio, oszustwa).

2.3 Diarizacja — kto mówi i kiedy

- **Definicja:** podział nagrania na fragmenty przypisane poszczególnym mówcom.
- **Co robi:** odpowiada na pytanie „kto mówił i kiedy" — zwykle etykietami (Mówca 1, Mówca 2), nie imionami.
- **Przykład:** transkrypcja spotkania, w której widać, kto co powiedział.
- **Analogia:** jakby ktoś rozdzielił dialog na role w scenariuszu.

3. Jak to się łączy (pipeline spotkania)

1. **Nagranie** spotkania.
2. **Speech-to-text** → tekst.
3. **Diarizacja** → kto mówił w którym momencie.
4. **Połączenie** → jedna transkrypcja z oznaczeniem mówców.
5. **Streszczenie** (często przez model językowy) → krótkie podsumowanie.

To właśnie robią automatycznie narzędzia takie jak ElevenLabs czy Fireflies (moduł 2 warsztatu).

---

4. Jak to działa (wysoki poziom, bez matematyki)

1. **Dźwięk** → komputer zamienia go na cechy (tzw. spektrogram — „obraz" dźwięku).
2. **Model** (sieć neuronowa) patrzy na te cechy i przewiduje tekst.
3. Model **uczy się** na milionach godzin nagrań — nie programujemy reguł „jeśli dźwięk X, to litera Y".

Wniosek: jakość zależy od danych, na których model się uczył, i od jakości nagrania.

---

5. Jakość: WER i CER

- **WER** (Word Error Rate) = błędy słów / wszystkie słowa referencyjne.
- **CER** (Character Error Rate) = to samo, ale na poziomie znaków.
- **Interpretacja:** mniej = lepiej; 0% = idealnie.
- **Typowo:** dobra transkrypcja czystej mowy to ~5–10% WER. Hałas, akcenty, żargon pogarszają wynik.
- W warsztacie (moduł 4) policzymy WER/CER na własnych nagraniach (biblioteka `jiwer`).

---

6. Zastosowania w psychologii

- Transkrypcja wywiadów badawczych i sesji (za zgodą).
- Analiza jakościowa: kodowanie, tematy, motywy.
- Dzienniki głosowe i EMA (ecological momentary assessment).
- Text-to-speech: materiały psychoedukacyjne, dostępność.
- Notatki ze spotkań i supervision.
- **Zawsze:** zgoda i poufność (patrz sekcja 8).

---

7. Ograniczenia i pułapki

- Szum tła, nakładanie się mów, akcenty, żargon.
- Utrata emocji i prozodii (tekst nie oddaje tonu głosu).
- **Halucynacje:** model może „dopisać" słowa, których nie było w nagraniu.
- Błędy mogą zmieniać sens — ważne w kontekście klinicznym i badawczym.
- Bias: modele mogą być mniej dokładne dla niektórych grup (akcenty, dialekty).

---

8. Prywatność — co warto wiedzieć (zapowiedź)

- **Chmura (API):** audio trafia na serwery dostawcy — pytaj: gdzie (UE/USA), retencja, czy używane do treningu, opt-out.
- **Lokalnie (Whisper):** dane nie opuszczają Twojej maszyny/sesji Colab.
- **Psychologia:** zgoda pacjenta/klienta, tajemnica zawodowa, minimalizacja danych.
- Szczegóły i ćwiczenie: moduł 2 (prywatność ElevenLabs) i moduł 4 (Whisper lokalnie).

9. Słownik pojęć

Pojęcie	Definicja
ASR	Automatic Speech Recognition — automatyczne rozpoznawanie mowy (mowa → tekst)
STT	Speech-to-text — zamiana mowy na tekst
TTS	Text-to-speech — zamiana tekstu na mowę (syntetyczny głos)
Voice cloning	Klonowanie głosu z krótkiego nagrania
Diarizacja	Podział nagrania na segmenty przypisane mówcom (kto mówi i kiedy)
Transkrypcja	Tekstowa wersja nagrania mowy
WER	Word Error Rate — błędy na poziomie słów
CER	Character Error Rate — błędy na poziomie znaków
Halucynacja	Gdy model „dopisuje" tekst, którego nie było w nagraniu
Model	System (sieć neuronowa) uczący się wzorców z danych
Dane treningowe	Nagrania/teksty, na których model się uczył
Latencja	Opóźnienie między mową a wynikiem
Czas rzeczywisty (real-time)	Przetwarzanie na bieżąco, bez czekania na koniec nagrania
Spektrogram	„Obraz" dźwięku używany przez modele
LLM	Large Language Model — model językowy (np. do streszczania transkrypcji)
API	Sposób komunikacji programu z usługą w chmurze
Chmura vs lokalnie	Czy przetwarzanie (i dane) odbywa się u dostawcy, czy na Twojej maszynie

10. Przydatne źródła

Podstawy:

- Wikipedia — Automatic speech recognition: https://en.wikipedia.org/wiki/Automatic_speech_recognition
- Wikipedia — Speech synthesis: https://en.wikipedia.org/wiki/Speech_synthesis
- Wikipedia — Word error rate: https://en.wikipedia.org/wiki/Word_error_rate

Whisper:

- OpenAI Whisper (opis): https://openai.com/research/whisper
- Artykuł (paper): https://arxiv.org/abs/2212.04356
- GitHub openai/whisper: https://github.com/openai/whisper
- faster-whisper: https://github.com/SYSTRAN/faster-whisper

Diarizacja:

- pyannote: https://github.com/pyannote/pyannote-audio
- WhisperX: https://github.com/m-bain/whisperX

Chmura / TTS:

- ElevenLabs docs: https://elevenlabs.io/docs
- ElevenLabs privacy: https://elevenlabs.io/privacy

Notatki ze spotkań:

- Fireflies: https://fireflies.ai

Dema (online):

- Hugging Face — Whisper: https://huggingface.co/spaces/openai/whisper

Środowisko warsztatu:

- Google Colab: https://colab.research.google.com

Prywatność (PL):

- UODO (ochrona danych): https://uodo.gov.pl

---

11. Co dalej w warsztacie

Moduł	Temat
2	Rozwiązania chmurowe (ElevenLabs, Fireflies) + prywatność
3	Python i Google Colab (praktyka)
4	Modele lokalne: Whisper w Colab, WER/CER, diarizacja
5	Podsumowanie i pytania

Materiały: repo BrainHack2026_ASR_Workshop · AIMed AGH