Modele lokalne (Whisper) — materiał dla uczestników

Warsztaty BrainHack 2026 — Rozpoznawanie i generowanie mowy
Moduł 4 (30 min) · Prowadzący: Franciszek Kubala, Mateusz Poszelężny - KN AIMed AGH

> Ten materiał towarzyszy części warsztatowej. Znajdziesz tu pojęcia, porównania i linki. Kod jest w notebooku `Local_ASR_models.ipynb` — nie musisz go pisać samodzielnie.

1. Co to „model lokalny” (Whisper)?

Whisper to model rozpoznawania mowy, który można uruchomić **u siebie**, na własnym komputerze. W sesji Google Colab działa ten sam model, ale na maszynie Google, więc to już chmura.

Analogia: tłumacz siedzący w pokoju z Tobą, a nie przez telefon do biura tłumaczeń.

Kluczowe: Whisper nie wysyła audio do API dostawcy ASR. Ale **to, gdzie leży plik, zależy od miejsca uruchomienia:**

- **Własny komputer** — audio zostaje u Ciebie.
- **Google Colab** — model działa bez API ASR, lecz plik trafia na maszynę Google. Colab to chmura, nie „lokalnie”.
- **API (ElevenLabs)** — audio trafia na serwery dostawcy ASR.

2. Chmura vs lokalnie

Kwestia	Chmura (API, np. ElevenLabs)	Colab (Whisper w chmurze Google)	Własny komputer (Whisper)
Gdzie idzie audio	Na serwery dostawcy ASR	Na maszynę Google, bez API ASR	Zostaje na Twoim komputerze
Retencja	Zależy od dostawcy (sprawdź politykę)	Zależy od Google i sesji; pliki znikają z sesji po zakończeniu	Ty decydujesz, co zachować
Trening modeli na Twoich danych	Możliwe (opt-out)	Sprawdź warunki Google	Nie dotyczy
Jakość	Często bardzo dobra	Zależy od modelu i zasobów	Zależy od modelu i zasobów
Czas i wygoda	Szybko, bez instalacji	Bez instalacji, w przeglądarce	Wymaga instalacji
Koszt	Limity/płatności	Darmowe limity	Darmowe (zależy od sprzętu)
Kontrola nad danymi	Ograniczona	Ograniczona	Pełna

Wniosek: wybór zależy od tego, co ważniejsze — wygoda/jakość czy prywatność/kontrola. Jeśli nagranie jest wrażliwe, zostaje tylko własny komputer.

3. Prywatność i zgoda (psychologia)

Checklist przed nagraniem sesji/wywiadu:

- [ ] **Zgoda** pacjenta/klienta (świadoma, dobrowolna, odwołalna).
- [ ] **Cel** nagrania jasno określony.
- [ ] **Gdzie** trafi nagranie i transkrypcja (chmura czy lokalnie).
- [ ] **Kto** ma dostęp i przez jak długo (retencja).
- [ ] **Anonimizacja** / pseudonimizacja w notatkach.
- [ ] **Tajemnica zawodowa** i minimalizacja danych.

Zasada: jeśli nagranie jest wrażliwe — preferuj model lokalny i nie wysyłaj audio do chmury bez podstawy prawnej.

---

4. Jak to wygląda w praktyce (Colab) — bez kodu

1. Otwórz notebook `Local_ASR_models.ipynb` w Google Colab.
2. Uruchom komórkę instalacyjną (jeden raz).
3. Wgraj własne nagranie (~1 min).
4. Uruchom transkrypcję (model działa w sesji Colab).
5. Zapisz wynik do pliku i pobierz na dysk.

Gdzie kod: w notebooku — wystarczy uruchamiać komórki (`Shift+Enter`). Nie musisz pisać kodu samodzielnie.

---

5. Zapis transkrypcji

- **txt** — zwykły tekst. Do archiwum, analizy jakościowej, cytatów.
- **SRT** — napisy z znacznikami czasu (format `HH:MM:SS,mmm`). Do wideo, do odsłuchiwania konkretnych fragmentów.

Po co zapisywać: archiwum, weryfikacja, cytowanie, analiza.

---

6. Jakość: WER i CER

- **WER** (Word Error Rate) = błędy słów / wszystkie słowa referencyjne.
- **CER** (Character Error Rate) = to samo na poziomie znaków.
- **Interpretacja:** mniej = lepiej; 0% = idealnie.
- **Typowo:** dobra transkrypcja czystej mowy to ~5–10% WER.
- **Co wpływa:** szum, akcenty, żargon, nakładanie się mów, jakość nagrania.

Jak liczymy w warsztacie: porównujemy ręczną transkrypcję (reference) z wynikiem modelu (hypothesis) — biblioteka `jiwer`.

---

7. Diaryzacja — skrót

- **Co to:** „kto mówi i kiedy” — podział nagrania na segmenty przypisane mówcom.
- **Lokalnie:** np. WhisperX lub pyannote (wymaga więcej zasobów i często tokena Hugging Face).
- **Dziś:** pokazujemy ideę; szczegóły i eksperymenty — samodzielnie (notebook, docs).

---

8. Kiedy chmura, kiedy lokalnie?

Wybierz **lokalnie**, gdy:

- nagranie jest wrażliwe (sesje, wywiady, dane pacjentów),
- potrzebujesz pełnej kontroli nad danymi,
- nie masz podstawy prawnej do wysyłania audio do chmury.

Wybierz **chmurę**, gdy:

- zależy Ci na wygodzie i szybkości,
- jakość musi być najwyższa (np. trudny akcent, żargon),
- masz zgodę i spełnione wymogi prawne.

---

9. Słownik pojęć

Pojęcie	Definicja
Model lokalny	Model działający na Twoim komputerze, bez wysyłania audio poza nim
Chmura (cloud)	Przetwarzanie na serwerach dostawcy
Retencja	Jak długo dane są przechowywane
Opt-out z treningu	Wyłączenie użycia danych do trenowania modeli
WER	Word Error Rate — błędy na poziomie słów
CER	Character Error Rate — błędy na poziomie znaków
SRT	Format napisów z znacznikami czasu
Colab	Google Colab — notebook w chmurze Google
HF token	Token Hugging Face (dostęp do modeli)
Diaryzacja	Podział nagrania na segmenty przypisane mówcom

---

10. Przydatne źródła

- faster-whisper: https://github.com/SYSTRAN/faster-whisper
- openai-whisper: https://github.com/openai/whisper
- jiwer (WER/CER): https://github.com/jitsi/jiwer
- WhisperX: https://github.com/m-bain/whisperX
- pyannote: https://github.com/pyannote/pyannote-audio
- Google Colab: https://colab.research.google.com
- Whisper (paper): https://arxiv.org/abs/2212.04356

---

11. Co dalej

- Notebook `Local_ASR_models.ipynb` — uruchom w Colab na własnym nagraniu.
- Moduł 5 — podsumowanie i pytania.

Materiały: repo BrainHack2026_ASR_Workshop · AIMed AGH